

# Prepoznavanje lica korištenjem tenzor-tenzor dekompozicija

Tri tenzora  
Bruno Ljubičić  
Hrvoje Olić  
Ermin Mustafić

May 21, 2023

# Sadržaj

- ▶ Cirkularne matrice i diskretna Fourierova transformacija
- ▶ Matrični pojmovi u tenzorskom okviru
- ▶ T-SVD
- ▶ Primjena u prepoznavanju lica
- ▶ Rezultati

# Cirkularne matrice

Za  $a = (a_0, \dots, a_{n-1})^T \in \mathbb{R}^n$  promatramo njenu cirkularnu matricu kao

$$\text{circ}(a) = \begin{bmatrix} a_0 & a_{n-1} & a_{n-2} & \cdots & a_1 \\ a_1 & a_0 & a_{n-1} & \cdots & a_2 \\ a_2 & a_1 & a_0 & \cdots & a_3 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n-1} & a_{n-2} & a_{n-3} & \cdots & a_0 \end{bmatrix}$$

Važno svojstvo cirkularnih matrica je da ih se može dijagonalizirati pomoću DFT matrica.

# DFT matrica

Za  $n \in \mathbb{N}$ , neka je  $\omega_n = e^{-\frac{2\pi i}{n}}$ . Matricu

$$F_n = \frac{1}{\sqrt{n}} \begin{bmatrix} \omega_n^{0 \cdot 0} & \omega_n^{0 \cdot 1} & \dots & \omega_n^{0 \cdot (n-1)} \\ \omega_n^{1 \cdot 0} & \omega_n^{1 \cdot 1} & \dots & \omega_n^{1 \cdot (n-1)} \\ \vdots & \vdots & \ddots & \vdots \\ \omega_n^{(n-1) \cdot 0} & \omega_n^{(n-1) \cdot 1} & \dots & \omega_n^{(n-1) \cdot (n-1)} \end{bmatrix}$$

zovemo (normaliziranom) DFT matricom reda  $n$ , a matricu  $F_n^* = \overline{F}_n$  (normaliziranom) IDFT matricom reda  $n$ .

## $\text{circ}(a)$ i DFT matrica

Može se pokazati da su  $F_n$  i  $\overline{F}_n$  unitarne matrice, te da su stupci od  $\overline{F}_n$  svojstveni vektori od  $\text{circ}(a)$ . Nadalje, svojstvene vrijednosti od  $\text{circ}(a)$  su vrijednosti vektora  $\sqrt{n}F_na$ . Dakle vrijedi

$$\text{circ}(a) = \overline{F}_n \text{diag}(\sqrt{n}F_na)F_n.$$

Za  $x \in \mathbb{R}^n$ , obično nam za množenje  $F_n x$  treba  $\mathcal{O}(n^2)$  operacija. Međutim, važno svojstvo DFT matrica je da se to množenje može obaviti u  $\mathcal{O}(n \log n)$  operacija. Gornja jednakost pokazuje da isto vrijedi i za cirkularne matrice.

# Ključna lema

**Lema A.** Neka je  $v = (v_1, \dots, v_n)^T \in \mathbb{R}^n$  te  $\hat{v} = \sqrt{n}F_nv$  njegova diskretna Fourierova transformacija. Tada je

$$\hat{v}_1 \in \mathbb{R}, \quad \overline{\hat{v}_k} = \hat{v}_{n-k+2}, \quad k = 2, \dots, \left\lceil \frac{n+1}{2} \right\rceil.$$

Obratno, ako vektor  $\hat{v} \in \mathbb{C}^n$  zadovoljava

$$\hat{v}_1 \in \mathbb{R}, \quad \overline{\hat{v}_k} = \hat{v}_{n-k+2}, \quad k = 2, \dots, \left\lceil \frac{n+1}{2} \right\rceil.$$

tada je  $v = \sqrt{n}\overline{F}_n\hat{v}$  realan.

# Osnovni pojmovi

Neka je  $\mathcal{A} \in \mathbb{R}^{l \times m \times n}$  tenzor te  $\mathcal{A}_{(1)}, \dots, \mathcal{A}_{(n)}$  njegovi frontalni slicevi tada je

$$\text{unfold}(\mathcal{A}) := \begin{bmatrix} \mathcal{A}_{(1)} \\ \mathcal{A}_{(2)} \\ \vdots \\ \mathcal{A}_{(n)} \end{bmatrix} \in \mathbb{R}^{ln \times m}$$

i  $\text{fold}(\text{unfold}(\mathcal{A})) = \mathcal{A}$ .

# Osnovni pojmovi

Definiramo operaciju cirkulante na tenzoru  $\mathcal{A} \in \mathbb{R}^{l \times m \times n}$  kao:

$$\text{bcirc}(\mathcal{A}) = \begin{bmatrix} \mathcal{A}_{(1)} & \mathcal{A}_{(n)} & \cdots & \mathcal{A}_{(2)} \\ \mathcal{A}_{(2)} & \mathcal{A}_{(1)} & \cdots & \mathcal{A}_{(3)} \\ \vdots & \vdots & \ddots & \vdots \\ \mathcal{A}_{(n)} & \mathcal{A}_{(n-1)} & \cdots & \mathcal{A}_{(1)} \end{bmatrix} \in \mathbb{R}^{ln \times mn}$$



# Osnovni pojmovi

Definiramo operaciju  $\text{bdiag}$   $\mathcal{A} \in \mathbb{R}^{l \times m \times n}$  kao:

$$\text{bdiag}(\mathcal{A}) = \begin{bmatrix} \mathcal{A}_{(1)} & & & \\ & \mathcal{A}_{(2)} & & \\ & & \ddots & \\ & & & \mathcal{A}_{(n)} \end{bmatrix} \in \mathbb{R}^{nl \times nm}.$$

# Osnovni pojmovi

Definiramo produkt dvaju tenzora  $\mathcal{A} \in \mathbb{R}^{l \times p \times n}$  i  $\mathcal{B} \in \mathbb{R}^{p \times m \times n}$  kao:

$$\mathcal{A} * \mathcal{B} = \text{fold}(\text{bcirc}(\mathcal{A})\text{unfold}(\mathcal{B})) \in \mathbb{R}^{l \times m \times n}$$

# Osnovni pojmovi

U prostoru tenzora s kvadratnim frontalnim slicevima  $\mathbb{R}^{l \times l \times n}$  postoji neutralni element za množenje - jedinični tenzor  $\mathcal{I}_{lln}$  koji se može dobiti kao:

$$\mathcal{I}_{lln} = \text{fold} \left( \begin{bmatrix} I_{ll} \\ \mathbf{0} \\ \mathbf{0} \\ \vdots \\ \mathbf{0} \end{bmatrix} \right).$$

Primijetimo da je  $\text{bcirc}(\mathcal{I}_{lln}) = I_{ln}$ .

Nadalje, uvodimo pojam  $f$ -dijagonalnosti. Kažemo da je tenzor  $f$ -dijagonalan ako mu je svaki frontalni slice dijagonalna matrica.

# Osnovni pojmovi

Transponiranje tenzora  $\mathcal{A} \in \mathbb{R}^{l \times m \times n}$  se realizira kao:

$$\mathcal{A}^T = \text{fold} \left( \begin{bmatrix} (\mathcal{A}_{(1)})^T \\ (\mathcal{A}_{(n)})^T \\ (\mathcal{A}_{(n-1)})^T \\ \vdots \\ (\mathcal{A}_{(2)})^T \end{bmatrix} \right) \in \mathbb{R}^{l \times m \times n}$$

Vrijedi  $\text{bcirc}(\mathcal{A}^T) = \text{bcirc}(\mathcal{A})^T$ .

Također definiramo i pojam ortogonalnog tenzora. Kažemo da je tenzor  $\mathcal{O}$  ortogonalan ako vrijedi:

$$\mathcal{O} * \mathcal{O}^T = \mathcal{O}^T * \mathcal{O} = \mathcal{I}$$

# Fourierova transformacija u trećem modu

Neka je  $\mathcal{A} \in \mathbb{R}^{l \times m \times n}$  tenzor. Tenzor  $\hat{\mathcal{A}} \in \mathbb{C}^{l \times m \times n}$  definiramo tako da svaku nit u modu 3 tenzora  $\mathcal{A}$  zamjenimo njenom diskretnom Fourierovom transformacijom.

To možemo zapisati preko frontalnih sliceva kao

$$\hat{\mathcal{A}}_{(k)} = \sum_{j=1}^n \omega_n^{(j-1)(k-1)} \mathcal{A}_{(j)}.$$

Koristeći lemu A., možemo zaključiti da vrijedi

$$\hat{\mathcal{A}}_{(1)} \in \mathbb{R}^{l \times m}, \quad \overline{\hat{\mathcal{A}}_{(k)}} = \hat{\mathcal{A}}_{(n-k+2)}, \quad k = 2, \dots, \left\lceil \frac{n+1}{2} \right\rceil.$$

## Lema B.

Neka je  $\mathcal{A} \in \mathbb{R}^{l \times m \times n}$ . Ako sa  $\hat{\mathcal{A}}$  označimo Fourierovu transformaciju tenzora  $\mathcal{A}$  u trećem modu. Tada vrijedi

(i)

$$\text{unfold}(\hat{\mathcal{A}}) = (\sqrt{n}F_n \otimes I_l)\text{unfold}(\mathcal{A}),$$

(ii)

$$(F_n \otimes I_l)\text{bcirc}(\mathcal{A})(\bar{F}_n \otimes I_m) = \text{bdiag}(\hat{\mathcal{A}})$$

# Lema B. - Dokaz (i)

$$\begin{aligned}
 \text{unfold}(\hat{\mathcal{A}}) &= \begin{bmatrix} \hat{\mathcal{A}}_{(1)} \\ \hat{\mathcal{A}}_{(2)} \\ \vdots \\ \hat{\mathcal{A}}_{(n)} \end{bmatrix} = \begin{bmatrix} \sum_{j=1}^n \omega_n^{(j-1)0} \mathcal{A}_{(j)} \\ \sum_{j=1}^n \omega_n^{(j-1)1} \mathcal{A}_{(j)} \\ \vdots \\ \sum_{j=1}^n \omega_n^{(j-1)(n-1)} \mathcal{A}_{(j)} \end{bmatrix} \\
 &= \begin{bmatrix} \omega_n^{00} I_l & \omega_n^{01} I_l & \dots & \omega_n^{0(n-1)} I_l \\ \omega_n^{10} I_l & \omega_n^{11} I_l & \dots & \omega_n^{1(n-1)} I_l \\ \vdots & \vdots & \ddots & \vdots \\ \omega_n^{(n-1)0} I_l & \omega_n^{(n-1)1} I_l & \dots & \omega_n^{(n-1)(n-1)} I_l \end{bmatrix} \begin{bmatrix} \mathcal{A}_{(1)} \\ \mathcal{A}_{(2)} \\ \vdots \\ \mathcal{A}_{(n)} \end{bmatrix} \\
 &= (\sqrt{n} F_n \otimes I_l) \text{unfold}(\mathcal{A}).
 \end{aligned}$$

## Lema B. - Dokaz (ii)

Zapišimo lijevu stranu u blok trokutastom formatu.

$$(F_n \otimes I_l) \text{bcirc}(\mathcal{A})(\overline{F}_n \otimes I_m) = \begin{bmatrix} K_{11} & K_{12} & \dots & K_{1n} \\ K_{21} & K_{22} & \dots & K_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ K_{n1} & K_{n2} & \dots & K_{nn} \end{bmatrix}$$

pri čemu su matrice  $K_{ij} \in \mathbb{R}^{l \times m}$ . Treba pokazati da je

$$K_{ij} = \delta_{ij} \hat{\mathcal{A}}_{(i)}, \quad \forall i, j = 1, \dots, n.$$



## Lema B. - Dokaz (ii)

Ako stavimo  $\mathcal{A}_{(n\pm i)} = \mathcal{A}_{(i)}$ , tada se koristeći isti rastav kao ranije, blok  $K_{ij}$  može zapisati kao

$$\begin{aligned} K_{ij} &= \frac{1}{n} \sum_{k_2=1}^n \sum_{k_1=1}^n \omega_n^{(i-1)(k_1-1)} \omega_n^{-(j-1)(k_2-1)} \mathcal{A}_{(k_1-k_2+1)} \\ &= \frac{1}{n} \sum_{k_2=1}^n \sum_{k_1=1}^n \omega_n^{(i-1)(k_1-1) - (i-1)(k_2-1) + (i-1)(k_2-1) - (j-1)(k_2-1)} \mathcal{A}_{(k_1-k_2+1)} \\ &= \frac{1}{n} \sum_{k_2=1}^n \sum_{k_1=1}^n \omega_n^{(i-1)(k_1-k_2) + (i-j)(k_2-1)} \mathcal{A}_{(k_1-k_2+1)} \\ &= \frac{1}{n} \sum_{k_2=1}^n \omega_n^{(i-j)(k_2-1)} \sum_{k_1=1}^n \omega_n^{(i-1)(k_1-k_2)} \mathcal{A}_{(k_1-k_2+1)} \\ &= \frac{1}{n} \sum_{k_2=1}^n \omega_n^{(i-j)(k_2-1)} \sum_{k_1=1}^n \omega_n^{(i-1)(k_1-1)} \mathcal{A}_{(k_1)} \\ &= \delta_{ij} \hat{\mathcal{A}}_{(i)} \end{aligned}$$

## Lema C.

**Lema C.** Neka su  $\mathcal{A} \in \mathbb{R}^{l \times p \times n}$ ,  $\mathcal{B} \in \mathbb{R}^{p \times m \times n}$  i  $\mathcal{C} \in \mathbb{R}^{l \times m \times n}$  ulančani tenzori. Tada vrijedi niz ekvivalencija

$$\begin{aligned}\mathcal{C} = \mathcal{A} * \mathcal{B} &\iff \text{unfold}(\mathcal{C}) = \text{bcirc}(\mathcal{A})\text{unfold}(\mathcal{B}) \\ &\iff \text{unfold}(\hat{\mathcal{C}}) = \text{bdiag}(\hat{\mathcal{A}})\text{unfold}(\hat{\mathcal{B}}) \\ &\iff \text{bdiag}(\hat{\mathcal{C}}) = \text{bdiag}(\hat{\mathcal{A}})\text{bdiag}(\hat{\mathcal{B}}) \\ &\iff \text{bcirc}(\mathcal{C}) = \text{bcirc}(\mathcal{A})\text{bcirc}(\mathcal{B}).\end{aligned}$$

Druga ekvivalencija nam daje efikasan način kako računati produkt tenzora.

$$\mathcal{A} * \mathcal{B} = \text{fold} \left( (\sqrt{n} \overline{F}_n \otimes I_l) \begin{bmatrix} \hat{\mathcal{A}}_{(1)} \hat{\mathcal{B}}_{(1)} \\ \vdots \\ \hat{\mathcal{A}}_{(n)} \hat{\mathcal{B}}_{(n)} \end{bmatrix} \right).$$

# Algoritam za tenzorsko množenje

---

**Algorithm 1** Algoritam za tenzorsko množenje

---

```
1: Inputs:  $\mathcal{A} \in \mathbb{R}^{l \times p \times n}, \mathcal{B} \in \mathbb{R}^{p \times m \times n}$ .  
2: Output:  $\mathcal{C} = \mathcal{A} * \mathcal{B}$ .  
3:  $\hat{\mathcal{A}} = \text{fft}(\mathcal{A}, [], 3)$   
4:  $\hat{\mathcal{B}} = \text{fft}(\mathcal{B}, [], 3)$   
5: for  $i = 1$  to  $n$  do  
6:    $\hat{\mathcal{C}}(:, :, i) = \hat{\mathcal{A}}(:, :, i) \hat{\mathcal{B}}(:, :, i)$   
7: end for  
8:  $\mathcal{C} = \text{ifft}(\hat{\mathcal{C}}, [], 3)$ 
```

---

Iz leme A. slijedi da za  $i = 2, \dots, \lceil \frac{n+1}{2} \rceil$  vrijedi

$$\hat{\mathcal{C}}_{(i)} = \overline{\hat{\mathcal{C}}_{(n-i+2)}}.$$

Kada bismo množenje vršili po definiciji, imali bismo  $\mathcal{O}(lpmn^2)$  operacija. Korištenjem brze Fourierove transformacije, kompleksnost ovog algoritma je  $\approx \mathcal{O}(lpmn)$ .

## Posljedica leme C

Iz ekvivalencije

$$\mathcal{C} = \mathcal{A} * \mathcal{B} \iff \text{bcirc}(\mathcal{C}) = \text{bcirc}(\mathcal{A})\text{bcirc}(\mathcal{B})$$

i asocijativnosti množenja matrica, odmah slijedi da je množenje tenzora isto asocijativno.

Nadalje, primijetimo da je  $\mathcal{Q}$  ortogonalan tenzor ako i samo kao je  $\text{bcirc}(\mathcal{Q})$  ortogonalna matrica. Zaista,

$$\begin{aligned}\mathcal{Q}^T * \mathcal{Q} &= \mathcal{Q} * \mathcal{Q}^T = \mathcal{I} \\ \iff \text{bcirc}(\mathcal{Q}^T * \mathcal{Q}) &= \text{bcirc}(\mathcal{Q} * \mathcal{Q}^T) = \text{bcirc}(\mathcal{I}) \\ \iff \text{bcirc}(\mathcal{Q})^T \text{bcirc}(\mathcal{Q}) &= \text{bcirc}(\mathcal{Q})\text{bcirc}(\mathcal{Q})^T = I.\end{aligned}$$

**Teorem.** Neka je  $\mathcal{A} \in \mathbb{R}^{l \times m \times n}$ . Tada se  $\mathcal{A}$  može faktorizirati kao:

$$\mathcal{A} = \mathcal{U} * \mathcal{S} * \mathcal{V}^T,$$

pri čemu je  $\mathcal{U} \in \mathbb{R}^{l \times l \times n}$  ortogonalan,  $\mathcal{V} \in \mathbb{R}^{m \times m \times n}$  ortogonalan, i  $\mathcal{S} \in \mathbb{R}^{l \times m \times n}$   $f$ -dijagonalan tenzor.

# T-SVD dokaz

**Dokaz.** Više puta ćemo koristiti Lemu A.

Po lemi A.,  $\hat{\mathcal{A}}_{(1)} \in \mathbb{R}^{l \times m}$ , pa postoji njena realna SVD dekompozicija

$$\hat{\mathcal{A}}_{(1)} = \hat{\mathcal{U}}_{(1)} \hat{\mathcal{S}}_{(1)} \hat{\mathcal{V}}_{(1)}^T.$$

Za  $k = 2, \dots, \lceil \frac{n+1}{2} \rceil$  izračunamo (kompleksnu!) SVD dekompoziciju slicea  $\hat{\mathcal{A}}_{(k)} = \hat{\mathcal{U}}_{(k)} \hat{\mathcal{S}}_{(k)} \hat{\mathcal{V}}_{(k)}^*$ .

Za  $k = \lceil \frac{n+1}{2} \rceil + 1, \dots, n$  stavimo da je

$$\hat{\mathcal{U}}_{(k)} = \overline{\hat{\mathcal{U}}_{(n-k+2)}}, \quad \hat{\mathcal{S}}_{(k)} = \overline{\hat{\mathcal{S}}_{(n-k+2)}}, \quad \hat{\mathcal{V}}_{(k)} = \overline{\hat{\mathcal{V}}_{(n-k+2)}}.$$

## T-SVD nastavak dokaza

Po lemi A., za  $k = \lceil \frac{n+1}{2} \rceil + 1, \dots, n$  vrijedi:

$$\hat{\mathcal{A}}_{(k)} = \overline{\hat{\mathcal{A}}_{(n-k+2)}} = \overline{\hat{\mathcal{U}}_{(n-k+2)} \hat{\mathcal{S}}_{(n-k+2)} \hat{\mathcal{V}}_{(n-k+2)}^*} = \hat{\mathcal{U}}_{(k)} \hat{\mathcal{S}}_{(k)} \hat{\mathcal{V}}_{(k)}^*.$$

Tenzore  $\hat{\mathcal{U}}$ ,  $\hat{\mathcal{S}}$  i  $\hat{\mathcal{V}}$  definiramo tako da su im  $k$ -ti frontalni slicevi redom  $\hat{\mathcal{U}}_{(k)}$ ,  $\hat{\mathcal{S}}_{(k)}$ ,  $\hat{\mathcal{V}}_{(k)}$ ,  $k = 1, \dots, n$ , a tenzore  $\mathcal{U}$ ,  $\mathcal{S}$  i  $\mathcal{V}$  kao njihove inverzne Fourierove transformacije po trećem modu. Po obratu leme A., slijedi da su  $\mathcal{U}$ ,  $\mathcal{S}$  i  $\mathcal{V}$  realni! Iz gornjih relacija slijedi

$$\text{bdiag}(\hat{\mathcal{A}}) = \text{bdiag}(\hat{\mathcal{U}}) \text{bdiag}(\hat{\mathcal{S}}) \text{bdiag}(\hat{\mathcal{V}}^*).$$

Množenjem s odgovarajućim  $(F_n \otimes I)$  i  $(\overline{F}_n \otimes I)$  dobivamo

$$\text{bcirc}(\mathcal{A}) = \text{bcirc}(\mathcal{U}) \text{bcirc}(\mathcal{S}) \text{bcirc}(\mathcal{V}^T)$$

što smo već pokazali da je ekvivalentno  $\mathcal{A} = \mathcal{U} * \mathcal{S} * \mathcal{V}^T$ .

$\hat{\mathcal{S}}$  je  $f$ -dijagonalni tenzor, a za  $k$ -ti frontalni slice od  $\mathcal{S}$  vrijedi

$$\mathcal{S}_{(k)} = \sum_{j=1}^n \omega_n^{-(j-1)(k-1)} \hat{\mathcal{S}}_{(j)}$$

pa je  $\mathcal{S}_{(k)}$  dijagonalna matrica, odnosno  $\mathcal{S}$  je  $f$ -dijagonalna tenzor. Nadalje,  $\text{bdiag}(\hat{\mathcal{U}})$  je unitarna matrica te

$$\text{bcirc}(\mathcal{U}) = (\bar{F}_n \otimes I_l) \text{bdiag}(\hat{\mathcal{U}}) (F_n \otimes I_l),$$

pa je i  $\text{bcirc}(\mathcal{U})$  unitarna matrica koja je realna, pa je ortogonalna. Analogno vrijedi za  $\mathcal{V}$ . □



## Teorem aproksimacije

O SVD dekompoziciji matrica znamo i puno više - jedna od tvrdnji je i o najboljoj aproksimaciji matrice onom nižeg ranga. Uz naš tenzorski produkt i prethodni teorem, vrijedi analogon:

**Teorem.** Neka je T-SVD dekompozicija tenzora  $\mathcal{A} \in \mathbb{R}^{l \times m \times n}$  dana s  $\mathcal{A} = \mathcal{U} * \mathcal{S} * \mathcal{V}^T$ . Nadalje, za  $k < \min\{l, m\}$  definirajmo:

$$\mathcal{A}_k = \sum_{i=1}^k \mathcal{U}(:, i, :) * \mathcal{S}(i, i, :) * \mathcal{V}(:, i, :)^T$$

Tada je

$$\mathcal{A}_k = \operatorname{argmin}_{\tilde{\mathcal{A}} \in M} \|\mathcal{A} - \tilde{\mathcal{A}}\|_{\mathcal{F}},$$

pri čemu je

$$M = \left\{ \mathcal{C} = \mathcal{X} * \mathcal{Y} \mid \mathcal{X} \in \mathbb{R}^{l \times k \times n}, \mathcal{Y} \in \mathbb{R}^{k \times m \times n} \right\}.$$

# T-QR dekompozicija

Ako slijedimo dokaz teorema o T-SVD dekompoziciji, pri čemu svaku SVD dekompoziciju frontalnih sliceva zamjenimo QR dekompozicijom

$$\hat{\mathcal{A}}_{(k)} = \hat{\mathcal{Q}}_{(k)} \hat{\mathcal{R}}_{(k)}, \quad k = 1, \dots, \left\lceil \frac{n+1}{2} \right\rceil,$$

dobivamo rastav  $\mathcal{A} = \mathcal{Q} * \mathcal{R}$  pri čemu su  $\mathcal{Q}$  i  $\mathcal{R}$  realni tenzori takvi da je  $\mathcal{Q}$  ortogonalan tenzor, a  $\mathcal{R}$  f-gornjetrokutasti tenzor (tenzor kojemu je svaki frontalni slice gornjetrokutasta matrica).

# PCA algoritam

---

## Algorithm 2 Matrični PCA

---

- 1: **Inputs:** Trening slike  $\mathbf{I}_i, i = 1, \dots, N$ , Testna slika  $\mathbf{J}$ , Indeks rezanja  $k$
  - 2: **Output:** Najbliža klasa (po nekoj mjeri) testnoj slici
  - 3:  $L(:, :, i) = \text{vektoriziraj}(\mathbf{I}_i)$
  - 4:  $\mathbf{A} = \text{kovarijacija}(L)$
  - 5:  $U = \text{lijevi singularni vektori od } \mathbf{A}$
  - 6:  $\mathbf{G} = U(:, 1 : k)^T \mathbf{A}$
  - 7:  $\mathbf{t} = \text{vektoriziraj}(\mathbf{J})$
  - 8:  $\mathbf{c} = U(:, 1 : k)^T \mathbf{t}$
  - 9: **for**  $i = 1$  **to**  $N$  **do**
  - 10:     Izračunaj udaljenost  $\|\mathbf{c} - \mathbf{G}(:, i)\|_F$
  - 11: **end for**
  - 12: Vрати indeks na kojem se izračunata udaljenost minimizira
-

# HOSVD algoritam

---

**Algorithm 3** HOSVD metoda

---

- 1: **Inputs:** Trening slike  $\mathbf{I}_{i,j}, i = 1, \dots, N, j = 1, \dots, M$ , Testna slika  $\mathbf{J}$
  - 2: **Output:** Najbliža klasa (po nekoj mjeri) testnoj slici
  - 3:  $L(:, :, i) = \text{vektORIZIRAJ}(\mathbf{I}_i)$
  - 4: HOSVD  $\mathcal{L} = \mathcal{S} \times_1 U_1 \times_2 U_2 \times_3 U_3$
  - 5:  $\mathcal{B} = \mathcal{S} \times_2 U_2 \times_3 U_3$
  - 6:  $\mathcal{T} = \text{vektORIZIRAJ}(\mathbf{J})$
  - 7: **for**  $e = 1$  **to**  $N_e$  **do**
  - 8:      $\mathbf{C}_e = \mathcal{C}(:, e, :)$
  - 9:      $\mathbf{x}_e = \mathbf{C}_e \mathcal{T}$
  - 10:    **for**  $p = 1$  **to**  $N_p$  **do**
  - 11:       Izračunaj udaljenost  $\|\mathbf{c} - U_1(:, p)\|_F$
  - 12:    **end for**
  - 13: **end for**
  - 14: Vрати индекс на којем се израчуната udaljenost minimizira
-

# T-SVD Algoritam

---

**Algorithm 4** Tenzorski SVD algoritam

---

- 1: **Inputs:** Trening slike  $\mathbf{I}_i, i = 1, \dots, N$ , Testna slika  $\mathbf{J}$
  - 2: **Output:** Najbliža klasa (po nekoj mjeri) testnoj slici
  - 3: **for**  $i = 1$  **to**  $N$  **do**
  - 4:      $L(:, :, i) = \text{vektoriziraj}(\mathbf{I}_i)$
  - 5: **end for**
  - 6:  $\mathcal{M} = \text{mean}(\mathbf{I})$
  - 7:  $\mathcal{A} = \text{kovarijacija}(L)$
  - 8:  $\mathcal{U} = \text{lijevi singularni tenzor od } \mathcal{A}$
  - 9:  $\mathcal{C} = \mathcal{U}(:, 1 : k, :)^T * \mathcal{A}$
  - 10:  $\mathcal{T} = \text{twst}(\mathbf{J} - \mathcal{M})$
  - 11:  $\mathcal{B} = \mathcal{U}(:, 1 : k, :)^T * \mathcal{T}$
  - 12: **for**  $i = 1$  **to**  $N$  **do**
  - 13:     Izračunaj udaljenost  $\|\mathcal{B} - \mathbf{C}(:, j)\|_F$
  - 14: **end for**
  - 15: Vрати индекс на којем се израчуната udaljenost minimizira
-

# T-QR Algoritam

---

**Algorithm 5** Tenzorski QR algoritam

---

- 1: **Inputs:** Trening slike  $\mathbf{I}_i, i = 1, \dots, N$ , Testna slika  $\mathbf{J}$
  - 2: **Output:** Najbliža klasa (po nekoj mjeri) testnoj slici
  - 3: **for**  $i = 1$  **to**  $N$  **do**
  - 4:      $L(:, :, i) = \text{vektORIZIRAJ}(\mathbf{I}_i)$
  - 5: **end for**
  - 6:  $\mathcal{M} = \text{mean}(\mathbf{I})$
  - 7:  $\mathcal{A} = \text{kovarijacija}(L)$
  - 8:  $\mathcal{Q}$  = ortogonalni tenzor iz T-QR faktorizacije
  - 9:  $\mathcal{C} = \mathcal{Q}(:, 1 : k, :)^T * \mathcal{A}$
  - 10:  $\mathcal{T} = \text{twst}(\mathbf{J} - \mathcal{M})$
  - 11:  $\mathcal{B} = \mathcal{Q}(:, 1 : k, :)^T * \mathcal{T}$
  - 12: **for**  $i = 1$  **to**  $N$  **do**
  - 13:     Izračunaj udaljenost  $\|\mathcal{B} - \mathbf{C}(:, j)\|_F$
  - 14: **end for**
  - 15: Vрати индекс на којем се израчуната udaljenost minimizira
-

# Podaci

Koristili smo 3 različita skupa podataka. Prva dva su iz Yaleove baze podataka o licima. Jedan skup podataka se sastoji od slika veličine 32x32, dok drugi 64x64 piksela. Ukupno smo koristili 165 slika (15 različitih osoba i 11 različitih ekspresija).



Figure: YALE 32x32 faces



Figure: YALE 64x64 faces

# Podaci

Zadnji skup podataka je iz ORL baze podataka o licima. Slike su veličine 64x64 piksela i ukupno imamo 400 slika (40 različitih osoba i 10 različitih ekspresija).



Figure: ORL 64x64 faces



# Prva metoda

Uspoređujemo 2 algoritma za prepoznavanje:

- ▶ Algoritam baziran na T-SVD
- ▶ Algoritam baziran na HOSVD

Metoda kojom smo testirali efikasnost algoritama je ta da smo iz dataseta u kojemu su dane slike osoba s različitim izrazima lica (ali za svaku osobu jednak broj izraza lica) je taj da smo za svaku ekspresiju izbacili sve pripadne slike iz dataseta te za svaku izbačenu sliku tražili u preostalim slikama iz dataseta njoj najslićniju pa ispitivali je li ispravno klasificirana.

# Prva metoda - rezultati

Točnosti metoda koje smo razmatrali su:

- ▶ Yale (32x32)
  - ▶ HOSVD - 120/165 (73 %)
  - ▶ TSVD - 114/165 (69 %)
  - ▶ PCA - 108/165 (65 %)
  - ▶ TQR - 113/165 (68 %)
- ▶ Yale (64x64)
  - ▶ HOSVD - 132/165 (80 %)
  - ▶ TSVD - 120/165 (73 %)
  - ▶ PCA - 115/165 (70 %)
  - ▶ TQR - 117/165 (71 %)
- ▶ ORL (64x64)
  - ▶ HOSVD - 368/400 (92 %)
  - ▶ TSVD - 347/400 (87 %)
  - ▶ PCA - 341/400 (85 %)
  - ▶ TQR - 346/400 (87 %)

## Druga metoda

Druga metoda s kojom smo testirali efikasnost algoritma je izbacivanje slika jednu po jednu, te ih potom klasificiramo na ostatku skupa podataka. Ova metoda je pogodna za sve algoritme osim HOSVD-a. Također, Za sve metode navodimo točnost i najmanji pripadni indeks rezanja  $k$  za koji se pripadna točnost postiže.

# Druga metoda rezultati

Točnosti metoda koje smo razmatrali su:

- ▶ Yale (32x32)
  - ▶ PCA - 107/165 (64.8 %),  $k = 17$
  - ▶ TQR - 109/165 (66.0 %),  $k = 16$
  - ▶ TSVD - 110/165 (66.6 %),  $k = 8$
- ▶ Yale (64x64)
  - ▶ PCA - 121/165 (73.3 %),  $k = 49$
  - ▶ TQR - 123/165 (74.5 %),  $k = 31$
  - ▶ TSVD - 122/165 (73.9 %),  $k = 16$
- ▶ ORL (64x64)
  - ▶ PCA - 373/400 (93.2 %),  $k = 35$
  - ▶ TQR - 380/400 (95.0 %),  $k = 20$
  - ▶ TSVD - 381/400 (95.3 %),  $k = 14$